

第二章：数据与度量

数据类型

记录数据

数据由记录集合组成，每个数据都有固定的属性集合。

<i>Tid</i>	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

属性的类型

属性（Attribute）的类型，本质上反映了该属性所对应数值的可进行哪些数学操作、能表达哪些现实意义。

不同类型的属性，决定了我们可以如何分析数据。

例如：

- 员工编号：只能区分不同员工，不能求平均值。
- 身高：可以比较大小，也可以计算差值与倍数。
- 温度（摄氏度）：可以比较高低，也能算温差，但不能说40°C是20°C的两倍热。

可以用以下性质（操作）来描述属性类型：

相异性（Distinctness）

表示数据是否能区分对象是否相同。

支持操作：

= ≠

例如：

- 学号
- 身份证号
- 邮政编码

这些值只能表示“不同”，不能表示大小。

有序性（Order）

表示数据是否可以排序。

支持操作：

< >

例如：

- 成绩等级：优 > 良 > 中 > 差
- 身高等级：高 > 中 > 矮

加法性（Addition）

表示数据差值有意义，可做加减法。

支持操作：

+ -

例如：

- 日期间隔
- 摄氏温差
- 分数差距

乘法性

表示倍数关系有意义，可做乘除法。

支持操作：

× ÷

例如：

- 长度
- 时间长度
- 质量
- 计数

根据以上四种性质，可以定义四种经典属性类型：

名词属性（Normal Attribute）

只能表示类别名称，用于区分对象，没有顺序关系。

- 具备性质：相异性

例子：

- ID号
- 眼睛颜色
- 邮政编码
- 性别
- 国籍

顺序属性（Ordinal Attribute）

数据之间存在顺序，但间隔大小不确定。

- 具备性质：相异性、有序性

例子：

- 比赛名次（第一、第二、第三）
- 满意度（差、中、好）
- 辣度等级（1~5级）
- 教师评级

区间属性（Interval Attribute）

数据之间差值有意义，但零点是人为定义的，不代表“没有”。

- 具备性质：相异性、有序性、加法性

例子：

- 摄氏温度 ($^{\circ}\text{C}$)
- 华氏温度 ($^{\circ}\text{F}$)
- 日期 (年份)



摄氏度不具备乘法性

40 $^{\circ}\text{C}$ 比 20 $^{\circ}\text{C}$ 热，但不能说是两倍热。因为0 $^{\circ}\text{C}$ 不是绝对零点。

比值属性 (Ratio Attribute)

具有绝对零点，可比较倍数关系。

- 具备性质：相异性、有序性、加法性、乘法性

例子：

- 开尔文温度 (K)
- 长度
- 重量
- 时间长度
- 收入
- 年龄
- 人数统计



比值属性的零代表不存在

可以说：

10kg 是 5kg 的两倍

4米 是 2米 的两倍


因为0表示真正不存在。

图数据


图可以表示数据对象之间的关系。

数据对象的关系可以表达重要的信息，这种情况下，数据通常组织成图结构。在图结构里，数据对象映射成图的节点，边的性质表示对象之间的关系，比如方向和权重。

另一种情况，如果对象有结构，即对象包含了具有相互关系的主体，那么对象本身就可以构成图。



对象本身构成了图结构



对象之间的关系构成了图结构

有序数据

数据的属性具有时间或空间顺序。

序列数据

单个实体的序列，例如词、字母的序列。序列数据一般需要考虑对象的位置。

```
GGTTCCGCCTTCAGCCCCGCGCC
CGCAGGGCCCGCCCCGCGCCGTC
GAGAAGGGCCCGCCTGGCGGGCG
GGGGGAGGCGGGGCGCCCGAGC
CCAACCGAGTCCGACCAGGTGCC
CCCTCTGCTCGGCCTAGACCTGA
GCTCATTAGGCGGCAGCGGACAG
GCCAAGTAGAACACGCGAAGCGC
TGGGCTGCCTGCTGCGACCAGGG
```

DNA序列数据

时序数据

时间与每个属性相关联。利用时序数据，可能会发现“买DVD播放器的人不久后就会买DVD”之类的模式。


系数（Jaccard Coefficient）

□用于度量两个离散集合的相

Time	Customer	Items Purchased
t1	C1	A, B
t2	C3	A, C
t2	C1	C, D
t3	C2	A, D
t4	C2	E
t5	C1	A, E

Customer	Time and Items Purchased
C1	(t1: A,B) (t2:C,D) (t5:A,E)
C2	(t3: A, D) (t4: E)
C3	(t2: A, C)

对每个顾客的（时间-购买物品）记录



温度-时间序列

空间数据

对象除了一般属性之外，还有空间属性，如位置和区域。例如气象数据（不同地区的降水量，气温，空气压力等）

➔ 图像和视频属于什么数据？

图像（无论黑白、灰度、彩色的）一般都看作为一个数据矩阵。属于记录数据。

视频一般看作是图像的序列，或者称之图像流，图像的前后顺序有重要含义。属于记录数据和有序数据的综合类型。

数据预处理

数据的归一化处理（Normalization）是指对原始数据进行变换，消除量纲，将数据值规范到 [0,1] 区间内。原始数据经过归一化处理后，各属性值处于同一数量级，解决了数据属性之间的可比性问题。

线性方法

$$\nu = \frac{x - \min}{\max - \min}$$

- ν 为归一化后的值
- x 为原始数据值
- $\max$ 是原始数据值中的最大值
- $\min$ 是原始数据值中的最小值

Z-Score方法


衡量一个变量离均值有多远。

$$\nu = \frac{x - \mu}{\sigma}$$


- ν 是归一化后的值
- x 为原始数据值
- μ 是所有原始数据值的均值
- σ 是所有原始数据值的标准差

其他可以从 $[-\infty, +\infty]$ 映射到 $[0, 1]$ 的函数

高斯函数



Sigmoid函数 (Logistic函数)



Softmax函数

$$v_i = \frac{e^{x_i}}{\sum_{k=1}^n e^{x_k}}$$

相似度

对象近似的程度可以用相似性和相异性来度量。

相似性

用数值度量两个数据对象的相似度。对象越相似，值越大。通常在区间 $[0, 1]$ 。

相异性

用数值度量两个数据对象的差异程度。对象越相似，值越小。

最小的相异度为0,但上界可变。

简单属性间的相似性和相异性

p 和 q 是两个数据对象的属性值

Attribute Type	Dissimilarity	Similarity
Nominal 名词	$d = \begin{cases} 0 & \text{if } p = q \\ 1 & \text{if } p \neq q \end{cases}$	$s = \begin{cases} 1 & \text{if } p = q \\ 0 & \text{if } p \neq q \end{cases}$
Ordinal 有序	$d = \frac{ p-q }{n-1}$ (values mapped to integers 0 to $n-1$, where n is the number of values)	$s = 1 - \frac{ p-q }{n-1}$
Interval or Ratio 区间或比值	$d = p - q $	$s = -d, s = \frac{1}{1+d}$ or $s = 1 - \frac{d - \min_d}{\max_d - \min_d}$


相异性度量

欧几里得距离 (Euclidean Distance)

$$dist = \sqrt{\sum_{k=1}^n (p_k - q_k)^2}$$

其中 n 是维数, p_k 和 q_k 分别是 p 和 q 的第 k 个属性值。

示例：



point	x	y
p1	0	2
p2	2	0
p3	3	1
p4	5	1

距离矩阵：

	p1	p2	p3	p4
p1	0	2.828	3.162	5.099
p2	2.828	0	1.414	3.162
p3	3.162	1.414	0	2
p4	5.099	3.162	2	0

欧氏距离的缺点：

1. 对变量尺度 (Scale) 非常敏感

核心逻辑： 欧氏距离是直接不同维度数值的差值平方相加。如果某个维度的数值范围特别大，它就会在距离计算中占据主导地位，导致数值范围小的维度被忽略。

例子： 假设我们要比较两个人的“身体差异”，用两个指标：身高（米）和年收入（元）。

- 甲：身高 1.80m，年收入 100,000 元
- 乙：身高 1.75m，年收入 101,000 元

身高那 5 厘米的差距在 1000 元的收入差距面前几乎可以忽略不计。但这在逻辑上是不合理的，因为身高的 5 厘米差异在生物学上可能比 1000 元的收入差异重要得多。

解决办法： 通常在计算前先做归一化 (Normalization) 或标准化 (Standardization)，把大家都拉到同一个数量级。

2. 不识别相关变量 (忽略相关性)

核心逻辑： 欧氏距离假设每个坐标轴（维度）都是相互独立的、垂直的。但现实数据中，很多变量之间有很强的相关性。如果直接算欧氏距离，相当于把重复的信息算了好几次。

例子： 假设我们要评估房子的“大小”，用了两个指标：面积（平方米）和房间数量。这两个变量显然是高度相关的（面积大的房子通常房间也多）。

- 如果你只看“面积”，你得到一个距离。
- 如果你把“面积”和“房间数”都放进去算欧氏距离，因为它们表达的是相似的信息，你实际上加重了“大小”这个属性的权重。

再极端一点，如果数据集里放了两个一模一样的变量（比如“身高-厘米”和“身高-米”），欧氏距离会把这个维度的差异计算两次。它看不出这两个变量其实是在说同一件事，导致最终结果向这些相关变量倾斜。

- **解决办法：** 可以使用马氏距离 (Mahalanobis Distance)，它会考虑变量之间的协方差；或者先用 PCA (主成分分析) 去掉相关性。

明科夫斯基距离 (Minkowski Distance)

$$dist = \left(\sum_{k=1}^n |p_k - q_k|^r \right)^{\frac{1}{r}}$$

其中，r 是参数，n 是维数，p_k 和 q_k 分别是 p 和 q 的第 k 个属性值。

$r = 1$ ：曼哈顿距离（ L_1 范数）

想象在像曼哈顿那样的方格路网中开车，不能横穿建筑，只能沿着水平和垂直的街道走。

$r = 2$ ：欧氏距离（ L_2 范数）

物理世界中最直观的“直线距离”。在二维空间里，它就是勾股定理的应用。

$r = \infty$ ：切比雪夫距离（ L_∞ 范数）

$$dist = \max(|p_1 - q_1|, |p_2 - q_2|, \dots, |p_n - q_n|)$$

两个点在所有维度差值中的**最大值**。

$r = 0$ ： L_0 范数

L_0 范数是指一个向量中**非零元素的个数**。

如果有一个向量 $\mathbf{x} = [1, 0, -3, 0, 5, 0]$ ：

- 这个向量中有 3 个元素不是零（分别是 1, -3, 5）。
- 那么，该向量的 L_0 范数 $\|\mathbf{x}\|_0 = 3$ 。

直白点说：它不关心数值的大小，只关心这个位置“有没有值”。

2. L_0 范数的核心作用：稀疏性 (Sparsity)

在数据处理中，如果我们希望得到一个**稀疏解**（即结果中大部分元素都是 0，只有极少数地方有值），那么 L_0 范数就是最理想的度量工具。

- **为什么要稀疏？**
 - **特征选择**：在成千上万个变量中，找出真正起作用的那几个。
 - **模型压缩**：去掉神经网络中那些微不足道的权重，减小模型体积。
 - **可解释性**：如果一个预测模型只依赖 3 个关键指标而不是 100 个，人类更容易理解。

马氏距离 (Mahalanobis Distance)

马氏距离就是 Z-score 标准化在多维空间中的推广。衡量一个向量距整体均值多远。

$$dist(p, q) = \sqrt{(p - q)^T \times \Sigma^{-1} \times (p - q)}$$

其中，p和q是m维向量， Σ^{-1} 是样本总体空间上的协方差矩阵的逆。



协方差矩阵

设有 n 个样本，每个样本是一个 m 维向量：

$$x^{(1)}, x^{(2)}, \dots, x^{(n)} \in \mathbb{R}^m$$

其中第 k 个样本写成：

$$x^{(k)} = [x_{k1} \quad x_{k2} \quad \cdots \quad x_{km}]$$

把所有样本排成矩阵：

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix} \in \mathbb{R}^{n \times m}$$

其中：

- 行数 n ：样本个数
- 列数 m ：特征维度

每一维特征的平均值：

$$\mu_j = \frac{1}{n} \sum_{k=1}^n x_{kj}, \quad j = 1, 2, \dots, m$$

组成均值向量：

$$\mu = [\mu_1 \quad \mu_2 \quad \cdots \quad \mu_m]$$

每个样本减去均值：

$$\tilde{x}^{(k)} = x^{(k)} - \mu$$

所有样本组成中心化矩阵：

$$X_c = X - \mathbf{1}\mu$$

其中：

$$\mathbf{1} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}_{n \times 1}$$

所以：

$$X_c = \begin{bmatrix} x^{(1)} - \mu \\ x^{(2)} - \mu \\ \vdots \\ x^{(n)} - \mu \end{bmatrix}$$

第 i 维与第 j 维的协方差：

$$\text{cov}(i, j) = \frac{1}{n} \sum_{k=1}^n (x_{ki} - \mu_i)(x_{kj} - \mu_j)$$

把所有协方差排列成矩阵：

$$\Sigma = \begin{bmatrix} \text{cov}(1, 1) & \text{cov}(1, 2) & \cdots \\ \text{cov}(2, 1) & \text{cov}(2, 2) & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

中心化矩阵：

$$X_c = \begin{bmatrix} - & - & -\tilde{x}^{(1)} & - & - & - \\ - & - & -\tilde{x}^{(2)} & - & - & - \\ & & \vdots & & & \\ - & - & -\tilde{x}^{(n)} & - & - & - \end{bmatrix}$$

则：

$$X_c^T X_c = \sum_{k=1}^n (\tilde{x}^{(k)})^T \tilde{x}^{(k)}$$

展开后第 (i, j) 个元素就是：

$$\sum_{k=1}^n (x_{ki} - \mu_i)(x_{kj} - \mu_j)$$

因此：

$$\boxed{\Sigma = \frac{1}{n} X_c^T X_c}$$

即：

$$\Sigma = \frac{1}{n}(X - \mathbf{1}\mu)^T(X - \mathbf{1}\mu)$$

例子（2维样本）

设有 3 个二维样本：

$$x^{(1)} = (1, 2)$$

$$x^{(2)} = (2, 3)$$

$$x^{(3)} = (3, 4)$$

样本矩阵：

$$X = \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ 3 & 4 \end{bmatrix}$$

第一步，求均值：

$$\mu_1 = \frac{1 + 2 + 3}{3} = 2$$

$$\mu_2 = \frac{2 + 3 + 4}{3} = 3$$

所以：

$$\mu = (2, 3)$$

第二步，中心化：

$$X_c = \begin{bmatrix} -1 & -1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}$$

第三步，计算协方差矩阵：

$$X_c^T X_c = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} -1 & -1 \\ 0 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$$

再除以 $n = 3$ ：

$$\Sigma = \frac{1}{3} \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.667 & 0.667 \\ 0.667 & 0.667 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{bmatrix}$$

其中：

- 对角线：方差（每一维波动大小）
- 非对角线：协方差（两个维度是否同步变化）

本例中两个维度完全同步增长，所以协方差较大且为正。

马氏距离的核心思想是，不看绝对差值，而看这个差值在总体分布里是否罕见。

设数据服从某种椭球分布：

$$x \sim (\mu, \Sigma)$$

其中：

- μ 是均值
- Σ 描述各维波动和相关性

若某方向方差大，说明该方向数据天然容易波动。那么该方向差异应该“折价”。

若某方向方差小，说明变化很敏感。那么该方向差异应该“放大”。

若只有一维，可以适用z-score的归一化方法：

$$z = \frac{x - \mu}{\sigma}$$

距离自然写成：

$$d = \left| \frac{x - \mu}{\sigma} \right|$$

一维里除以方差：

$$\frac{(x - \mu)^2}{\sigma^2}$$

多维中，方差变成矩阵 Σ ，于是自然推广为：

$$(x - \mu)^T \Sigma^{-1} (x - \mu)$$

再开根号：

$$d(x, \mu) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)}$$

这就是点到总体中心的马氏距离。

两个点之间有：

$$d(p, q) = \sqrt{(p - q)^T \Sigma^{-1} (p - q)}$$



为什么是逆矩阵？

协方差矩阵起到“缩放坐标轴”的作用。若：

$$\Sigma = \begin{bmatrix} 9 & 0 \\ 0 & 1 \end{bmatrix}$$

说明：

- 第1维波动大（方差9）
- 第2维波动小（方差1）

逆矩阵：

$$\Sigma^{-1} = \begin{bmatrix} 1/9 & 0 \\ 0 & 1 \end{bmatrix}$$

于是：

- 第1维差异被缩小
- 第2维差异保留

这正符合统计意义。



几何意义

欧氏距离的等距离线是圆：

$$x^2 + y^2 = r^2$$

马氏距离的等距离线是椭圆：

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = c^2$$

因为真实数据分布通常是椭圆状，而不是完美圆形。

所以马氏距离是在“顺着数据形状”测距离。



例子

设二维协方差矩阵：

$$\Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}$$

两个点：

$$p = (0, 0), \quad q = (2, 1)$$

欧氏距离：

$$\sqrt{2^2 + 1^2} = \sqrt{5}$$

马氏距离：

$$\Sigma^{-1} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1 \end{bmatrix}$$

$$d = \sqrt{\begin{bmatrix} 2 & 1 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix}} = \sqrt{2}$$

说明第1维变化本来就大，所以差异没那么严重。

马氏距离的优点：

- 不受量纲的影响，与原始数据的测量单位无关
- 可以排除变量之间相关性的干扰

马氏距离的缺点：

- 马氏距离的计算是建立在总体样本的基础上，同样两个样本在不同总体中的马氏距离通常不同，除非这两个总体的协方差矩阵碰巧相同
- 马氏距离是不稳定的，不稳定的来源是协方差矩阵，如果数据集中存在几个极端的离群点，它们会极大地拉伸协方差矩阵的特征值。
- 计算马氏距离要求总体样本数大于样本维数，否则总体样本协方差矩阵逆矩阵不存在。
- 若样本点共线，则其协方差矩阵的逆矩阵依然存在。

度量公理

距离是一种度量。假设 $d(p, q)$ 是两个点（数据对象） p 和 q 之间的 距离，则其必须满足以下条件：

- 非负性：对于所有的p和q都有 $d(p, q) \geq 0$ ，如果 $p = q$ ，则 $d(p, q) = 0$ 。
- 对称性：对于所有的p和q，都有 $d(p, q) = d(q, p)$
- 三角不等式法则：对于所有的p, q, 和r, $d(p, r) \leq d(p, q) + d(q, r)$ 。

相似性度量

相似性的度量一般有以下性质：

假设 $s(p, q)$ 是两个点p和q的相似度，则：

- 最大相似度： $s(p, q) = 1$ ，当且仅当 $p = q$ 。
- 对称性：对所有的p和q, $s(p, q) = s(q, p)$ 。

余弦相似度

$$\cos(\mathbf{p}, \mathbf{q}) = \frac{\mathbf{p} \cdot \mathbf{q}}{\|\mathbf{p}\| \|\mathbf{q}\|} = \frac{\sum_{k=1}^n p_k \times q_k}{\sqrt{\sum_{k=1}^n p_k^2} \sqrt{\sum_{k=1}^n q_k^2}}$$

- 值域为 $[-1, 1]$
- 两个向量夹角为0时相似度为1，方向完全相反时为-1
- n 是维数
- p_k 和 q_k 分别是p和q的第k个属性值。

距离倒数

$$s = \frac{1}{1 + d}$$

- 值域为 $[0, 1]$
- 把欧氏距离从 $[0, +\infty]$ 转换为相似性度量

杰卡德系数 (Jaccard Coefficient)

用于衡量两个离散集合的相似度。

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

杰卡德系数 = 交集大小 / 并集大小。取值范围为[0,1]，值越大表示相似度越高。

对应可以得到杰卡德距离，用于衡量相异度。：

$$d_J(A, B) = 1 - J(A, B)$$

杰卡德距离是一种度量。

Tanimoto系数 (Tanimoto Coefficient)

是Jaccard相似度的一个变形，值域为[0, 1].

$$f(A, B) = \frac{A \cdot B}{|A|^2 + |B|^2 - A \cdot B}$$



将离散集合概念扩展到多维向量空间

Tanimoto系数公式中，向量的点积定义为：

$$A \cdot B = \sum_{k=1}^n A_k B_k$$

向量的模的平方定义为：

$$|A|^2 = \sum_{k=1}^n A_k A_k = \sum_{k=1}^n A_k^2$$

假设有两个用户 A 和 B，他们购买商品的情况如下：

- 用户 A：{可乐, 薯片, 面包}
- 用户 B：{可乐, 薯片, 啤酒}

1. 使用杰卡德系数 (Jaccard)

此时我们把商品看作集合。

- 交集 ($A \cap B$)：{可乐, 薯片}，个数为 2。
- 并集 ($A \cup B$)：{可乐, 薯片, 面包, 啤酒}，个数为 4。
- 计算： $J(A, B) = \frac{2}{4} = 0.5$
- 结论：两个用户的兴趣重合度为 50%。

2. 使用 Tanimoto 系数

此时我们考虑购买数量，将其看作向量。

假设向量维度为（可乐, 薯片, 面包, 啤酒），则：

$$A = [1, 1, 1, 0]$$

$$B = [1, 1, 0, 1]$$

- 点积 $A \cdot B$ ： $1 \times 1 + 1 \times 1 + 1 \times 0 + 0 \times 1 = 2$
- $|A|^2$ ： $1^2 + 1^2 + 1^2 + 0^2 = 3$
- $|B|^2$ ： $1^2 + 1^2 + 0^2 + 1^2 = 3$
- 计算： $f(A, B) = \frac{2}{3+3-2} = \frac{2}{4} = 0.5$

在处理二元数据（0/1）时，两者结果一致；但如果用户 A 买了 10 瓶可乐，Tanimoto 系数能捕捉到强度的变化，而杰卡德不行。

为什么 Tanimoto 距离不是“度量”？

在数学中，一种距离要被称为“度量 (Metric)”，必须满足：非负性、同一性、对称性和三角不等式。

Tanimoto 距离（即 $1 - f(A, B)$ ）在处理连续型数值向量时，不一定满足三角不等式。

- **三角不等式要求：** $d(A, C) \leq d(A, B) + d(B, C)$ 。
- **失效点：** Tanimoto 系数的分母包含点积项，这种非线性缩放会导致在某些高维空间或特定数值下，直接距离比“绕路”距离还要长。
- **后果：** 由于它不是严格的度量，某些依赖空间几何特性的算法（如部分索引加速算法）可能无法直接应用。

Dice系数 (Dice Coefficient)

值域为[0, 1].

$$S(A, B) = \frac{2|A \cap B|}{|A| + |B|}$$

与Jaccard系数比较类似，二者关系为：

$$J = \frac{S}{2 - S}$$

$$S = \frac{2J}{1 + J}$$

但是Dice距离 $1 - S(A, B)$ 不是度量，不满足三角不等式。它对公共部分给予了双倍权重，在距离计算中会导致非线性的空间扭曲。



范例证明

假设有三个集合：

- $A = \{1\}$
- $B = \{2\}$
- $C = \{1, 2\}$

Dice 距离计算 ($d = 1 - S$)

1. $d(A, C)$ ：交集为 1，分母 $1 + 2 = 3$ 。 $S = 2/3$ ，则 $d(A, C) = 1/3$ 。
2. $d(B, C)$ ：交集为 1，分母 $1 + 2 = 3$ 。 $S = 2/3$ ，则 $d(B, C) = 1/3$ 。
3. $d(A, B)$ ：交集为 0。 $S = 0$ ，则 $d(A, B) = 1$ 。

验证三角不等式：

- $d(A, B) \leq d(A, C) + d(B, C)$
- $1 \leq 1/3 + 1/3 \implies 1 \leq 2/3$ (不成立)
- **结论**：Dice 距离不满足三角不等式。

Jaccard 距离计算 ($d = 1 - J$)

1. $d(A, C)$ ：并集为 2。 $J = 1/2$ ，则 $d(A, C) = 1/2$ 。
2. $d(B, C)$ ：并集为 2。 $J = 1/2$ ，则 $d(B, C) = 1/2$ 。
3. $d(A, B)$ ：并集为 2。 $J = 0$ ， $d(A, B) = 1$ 。

验证三角不等式：

- $1 \leq 1/2 + 1/2 \implies 1 \leq 1$ (成立)

皮尔逊相关系数 (Pearson Correlation Coefficient)

用于衡量线性相关。值域为 $[-1, 1]$ 。

$$\rho_{XY} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2} \sqrt{\sum_{k=1}^n (y_k - \bar{y})^2}}$$


其中，X和Y是两个n维随机变量。

$$X = [x_1, x_2, x_3, \dots, x_n]$$

$$Y = [y_1, y_2, y_3, \dots, y_n]$$

可以理解为向量的点积除以向量的模。

线性正相关为1，线性负相关为-1，线性无关为0。



不同线性相关程度的图示。第三列的数据点呈现了一些规律，但为非线性相关。

斯皮尔曼相关系数 (Spearman Correlation Coefficient)

用数据的“位置”，“排位”（秩）来计算相关性。

计算本质：它其实就是先把原始数据转成**排名**，然后再对排名算皮尔逊（Pearson）相关系数。

$$\text{Spearman}(X, Y) = \text{Pearson}(R(X), R(Y)) = \frac{\text{cov}(R(X), R(Y))}{\sigma_{R(X)}\sigma_{R(Y)}}$$

其中，

$$R(X)$$

为X的秩序，即对应原始变量的排列位置。

非参数性质：它对数据的分布没有要求（不需要符合正态分布）。哪怕数据里有“离群值”（特别大或特别小的极端值），对它的影响也很小。

单调联系：它衡量的是“单调性”。只要Y随着X的增加而增加（哪怕不是直线增加，而是曲线增加），斯皮尔曼系数就会很高。



例子

下表展示了 4 名学生的原始数据及其对应的排名（秩）：

学生	学习小时 (X)	考试得分 (Y)	X 的排名 R(X)	Y 的排名 R(Y)
小明	2	50	1	1
小刚	5	70	2	2
小红	10	85	3	3
小亮	50	98	4	4

结果分析：

- **原始数据**：虽然学习小时从 10 跳到 50（非线性增长），但得分趋势是持续上升的。
- **秩的关系**：X 的排名序列为 [1, 2, 3, 4]，Y 的排名序列也完全一致。
- **系数结论**：由于排名完全同步，该组数据的斯皮尔曼相关系数 $\rho = 1$ 。



对比Pearson系数

Pearson（皮尔逊）：必须是**直线**关系。如果数据是曲线增长（比如指数增长），Pearson 系数会偏低。

Spearman（斯皮尔曼）：只要是**向上走**的（单调），管你是直线还是曲线，它都能精准捕捉。

不怕脏数据：如果小亮考试得了 10000 分（显然是录入错误），Pearson 会被带跑偏，但 Spearman 只看他是“第一名”，结果依然稳定。

熵（Entropy）

源于物理学概念，度量状态的混乱程度。信息熵用于度量信息量的多少，0熵代表每个信息都没有任何差异，所有数据一致（也就没有任何的信息量）。

在信息学里，熵的公式为：

$$En_i = -p_i \log_2 p_i = p_i \log_2 \frac{1}{p_i}$$

$$En = \sum_{i=1}^k En_i = - \sum_{i=1}^k p_i \log_2 p_i$$

其中，p是状态的概率。



如何理解信息熵的公式

1. 自信息量： $I(x_i) = \log_2 \frac{1}{p(x_i)}$ (惊奇度)

- **核心逻辑**：信息量 = 消除的不确定性 = “这件事有多让人意外”。
- **高概率事件**：如果某事 100% 发生 ($p = 1$)，它就不包含新信息 ($\log 1 = 0$)。
- **低概率事件**：如果一件极罕见的事发生了，它包含的信息量巨大。
- **对数作用**：使用 $\log$ 是为了让信息具有“可加性”。例如：抛两次硬币的信息量 (1+1) 等于抛一次的 2 倍。

2. 负号的含义：为什么前面有个“-”？

- 数学上， $\log(\frac{1}{p})$ 等同于 $-\log(p)$ 。
- 由于概率 p 永远在 0 到 1 之间， $\log(p)$ 的值永远是负数。
- 前面的负号是为了将结果抵消为**正数**，符合我们对“量”的直观理解。

3. 加权平均 (期望值)： $\sum p(x_i) \dots$

- 信息熵不是指“某一个结果”的信息量，而是整个系统所有可能结果的**平均信息量**。
- 我们将每个结果的“惊奇度”乘以它发生的“概率”，然后求和。



直观总结

- $H(X)$ ：每看一次随机变量结果，平均能得到多少“惊喜”。
- **单位**：通常以 2 为底，单位是 **比特 (bit)**。
- **最大熵**：当所有可能的结果概率相等时（最混乱、最难预测），熵最大。
- **最小熵**：当某个结果必然发生时 ($p = 1$)，系统完全确定，熵为 0。

交叉熵

衡量模型预测概率分布 q 与真实标签分布 p 的吻合程度。

$$CE_i = -p_i \log_2 q_i = p_i \log_2 \frac{1}{q_i}$$

$$CE(p, q) = \sum_{i=1}^k CE_i = - \sum_{i=1}^k p_i \log_2 q_i$$

- p_i ：真实分布 (Labels)。通常是 One-hot 编码 (如 `[1, 0, 0]`)。

- q_i ：预测分布（Predictions）。模型输出的概率（如 `[0.9, 0.05, 0.05]`）。



One-Hot 编码（独热编码）

一种将分类变量（类别数据）转换为数值向量的算法。它的核心规则是：在一个 N 维的向量中，只有一个位置是 1，其余全部为 0。

交叉熵是解决分类问题最常用的函数（损失函数）。损失函数越小，就说明正确的概率越大。



举例说明：动物分类器

假设我们要预测一张图片是 **猫、狗、还是猪**。已知这张图片真实情况是**猫**。

情况 A：预测非常准

- 真实分布 p ：`[1, 0, 0]`（100% 是猫）
- 预测分布 q_1 ：`[0.9, 0.05, 0.05]`（模型很有信心是猫）
- 计算： $-(1 \times \log 0.9 + 0 \times \log 0.05 + 0 \times \log 0.05) \approx 0.15$
- 结论：交叉熵越小，表示预测越接近真实，模型表现越好。

情况 B：预测非常差

- 真实分布 p ：`[1, 0, 0]`
- 预测分布 q_2 ：`[0.1, 0.1, 0.8]`（模型认为 80% 的概率是猪）
- 计算： $-(1 \times \log 0.1 + 0 \times \log 0.1 + 0 \times \log 0.8) \approx 3.32$
- 结论：交叉熵越大，表示预测偏离真实，模型受到的“惩罚”越大。



核心直觉

- 惩罚机制：当真实标签为 1 但预测值趋近于 0 时， $\log(q)$ 会趋向负无穷，导致交叉熵剧增。
- 训练目标：机器学习的训练过程，就是通过梯度下降不断减小交叉熵的过程。

KL散度（Kullback-Leibler Divergence）

KL 散度（也叫相对熵）用于衡量一个概率分布 q 相对于另一个参考分布 p 的信息损失。在机器学习中，它代表当我们用预测分布 q 来近似真实分布 p 时，产生了多少额外的信息成本。

$$KL(p||q) = \sum_{i=1}^k p_i \log_2 \frac{p_i}{q_i} = \sum_{i=1}^k p_i (\log_2 p_i - \log_2 q_i)$$

- p_i ：真实分布（基准）。

- q_i ：近似分布（模型预测）。
- 特性：
 - **非对称性**： $D_{KL}(p||q) \neq D_{KL}(q||p)$ （所以它不是真正的“距离”）。
 - **非负性**： $D_{KL} \geq 0$ 。当且仅当 $p = q$ 时，结果为 0。



为什么非对称？

$D_{KL}(p||q) \neq D_{KL}(q||p)$ 。

- $D_{KL}(\text{真实}||\text{预测})$ ：衡量忽略了真实世界中哪些重要信息。
- $D_{KL}(\text{预测}||\text{真实})$ ：衡量预测模型中包含了多少真实世界并不存在的虚假噪声。
- 在优化模型时，我们永远是以**真实分布** p 为基准。

交叉熵、信息熵和 KL 散度之间存在一个非常直观的等式：

$$H(p, q) = H(p) + D_{KL}(p||q)$$

- $H(p)$ （**信息熵**）：真实分布本身的复杂度（不可改变的底噪）。
- $D_{KL}(p||q)$ （**KL 散度**）：由于预测不准带来的额外损失。
- $H(p, q)$ （**交叉熵**）：总的编码成本。

在优化模型时（比如训练神经网络）：

1. **真实分布 p 是固定的**（标签不会变），所以 $H(p)$ **是一个常数**。
2. 最小化 **交叉熵** $H(p, q)$ 在数学上等同于最小化 **KL 散度** $D_{KL}(p||q)$ 。



理解交叉熵、KL散度的公式

KL散度：

$$D_{KL}(p||q) = \sum p(x) \log \frac{p(x)}{q(x)} = \sum p(x) \log p(x) - \sum p(x) \log q(x)$$

- **物理意义：**衡量“用 q 来代表 p ”时产生的**额外信息量**。
- **直观理解：**它是两个分布之间的“不匹配度”。如果 $p = q$ ，则 $\log(1) = 0$ ，散度为 0。

交叉熵：

$$H(p, q) = - \sum p(x) \log q(x)$$

- **物理意义：**衡量“用 q 分布的编码策略去编码 p 分布的消息”所需的**总平均长度**。
- **三者关系：** $H(p, q) = H(p) + D_{KL}(p||q)$
 - **交叉熵 = 真实信息熵（原件大小） + KL 散度（压缩损失）。**

实例说明：天气预报

假设某地只有两种天气：**晴天** 和 **雨天**。

- **真实概率 p ：**晴天 80%，雨天 20% —— $[0.8, 0.2]$
- **模型 A 预测 q_A ：**晴天 70%，雨天 30% —— $[0.7, 0.3]$ （比较准）
- **模型 B 预测 q_B ：**晴天 20%，雨天 80% —— $[0.2, 0.8]$ （完全反了）

计算 KL 散度（衡量差异）

- **模型 A：** $0.8 \log \frac{0.8}{0.7} + 0.2 \log \frac{0.2}{0.3} \approx \mathbf{0.025}$ （差异很小）
- **模型 B：** $0.8 \log \frac{0.8}{0.2} + 0.2 \log \frac{0.2}{0.8} \approx \mathbf{0.831}$ （差异巨大）

计算交叉熵（衡量成本）

- **模型 A：** $-(0.8 \log 0.7 + 0.2 \log 0.3) \approx \mathbf{0.74}$
- **模型 B：** $-(0.8 \log 0.2 + 0.2 \log 0.8) \approx \mathbf{1.54}$

概念	关注点	机器学习中的角色
信息熵 $H(p)$	数据的本质	标签的固有复杂度（通常是常数）
KL 散度 D_{KL}	两个分布的差异	衡量模型预测分布偏离真相的程度
交叉熵 $H(p, q)$	编码的总成本	损失函数： 因为计算更简单，优化它等同于优化 KL 散度

互信息

互信息（Mutual Information，简称 MI）是信息论中衡量两个变量之间相互依赖程度的指标。简单来说，它告诉你：如果我们知道了变量 X，能在多大程度上减少对变量 Y 的不确定性。

互信息通常定义为两个随机变量 X 和 Y 的联合概率分布 $P(X, Y)$ 与边缘分布乘积 $P(X)P(Y)$ 之间的 **相对熵**（Kullback–Leibler 散度）：

$$I(X; Y) = \sum_{x \in X} \sum_{y \in Y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

用熵来表示则为

- $I(X; Y) = H(Y) - H(Y|X)$ ，原本的不确定性减去已知 X 后的不确定性。
- $I(X; Y) = H(X) + H(Y) - H(X, Y)$ ，两个人的信息总量减去并集，剩下的就是重合部分。



概念解释和例子说明

A. 联合概率分布 $P(X, Y)$

联合分布衡量的是两个变量同时发生的真实情况。

- 物理意义：它捕捉了变量 X 和 Y 之间所有的相关性（线性、非线性、依赖关系）。
- 直观理解：如果你观察一对数据（比如“气温”和“冰淇淋销量”），联合分布告诉你这两者在现实中是如何“捆绑”出现的。

B. 边缘分布乘积 $P(X)P(Y)$

边缘分布乘积是基于“独立性假设”的推导结果。

- 物理意义：它是假设 X 和 Y 完全没有任何关系时，理论上应该出现的分布。
- 直观理解：如果你把 X 的规律和 Y 的规律拆开单独看，然后再强行乘在一起，就得到了这个“无关联”模型。

C. 两者的关系

互信息 $I(X; Y)$ 本质上就是在衡量 $P(X, Y)$ 偏离 $P(X)P(Y)$ 有多远：

- 如果两者相等 $\Rightarrow X$ 与 Y 独立 $\Rightarrow I(X; Y) = 0$ 。
- 如果两者差异极大 $\Rightarrow X$ 与 Y 强相关 $\Rightarrow I(X; Y)$ 值很大。

D. 举例说明：计算互信息

假设我们有一个实验：

1. 变量 X ：抛硬币的结果（正面 x_1 ，反面 x_2 ）。概率各为 0.5。
2. 变量 Y ：抽奖结果（中奖 y_1 ，不中奖 y_2 ）。

情况 A：完全独立（互信息为 0）

如果抛硬币不影响抽奖：

- $P(x_1, y_1) = P(x_1) \times P(y_1)$

情况 B：存在依赖（我们要计算的情况）

假设硬币如果是正面，中奖概率会更高。联合分布 $P(X, Y)$ 如下表：

$P(X, Y)$	中奖 (y_1)	不中奖 (y_2)	边缘分布 $P(X)$
正面 (x_1)	0.4	0.1	0.5
反面 (x_2)	0.2	0.3	0.5
边缘分布 $P(Y)$	0.6	0.4	1.0

第一步：计算边缘分布乘积 $P(X) \cdot P(Y)$

- $P(x_1)P(y_1) = 0.5 \times 0.6 = 0.30$
- $P(x_1)P(y_2) = 0.5 \times 0.4 = 0.20$

- $P(x_2)P(y_1) = 0.5 \times 0.6 = 0.30$
- $P(x_2)P(y_2) = 0.5 \times 0.4 = 0.20$

第二步：应用互信息公式

$$I(X; Y) = \sum_{x,y} P(x, y) \log_2 \frac{P(x, y)}{P(x)P(y)}$$

1. 项 1 (正, 中): $0.4 \times \log_2(0.4/0.3) = 0.4 \times 0.415 = 0.166$
2. 项 2 (正, 没中): $0.1 \times \log_2(0.1/0.2) = 0.1 \times (-1) = -0.1$
3. 项 3 (反, 中): $0.2 \times \log_2(0.2/0.3) = 0.2 \times (-0.585) = -0.117$
4. 项 4 (反, 没中): $0.3 \times \log_2(0.3/0.2) = 0.3 \times 0.585 = 0.1755$


第三步：求和得到最终结果

$$I(X; Y) = 0.166 - 0.1 - 0.117 + 0.1755 = \mathbf{0.1245 \text{ bits}}$$

这意味着抛硬币的结果 X 确实包含了关于抽奖结果 Y 的部分信息。如果我们观察到了硬币是正面，我们对“是否中奖”的预测准确度会提高，这种提高的量化值就是 0.125 比特。

互信息具有如下性质：

- 非负性
- 对称性
- X 与 Y 无关（相互独立）时， $I(X, Y) = 0$
- X 与 Y 完全相关时（由 X 可以推出 Y 或反之时）， $I(X, Y) = H(Y) = H(X)$



评价机器学习结果

机器学习一般不要求结果100%正确。

评估原则

- 学习结果的合理性和有效性：模型的泛化能力（Generalization）越强越好



泛化能力

指机器学习或深度学习模型在未见过的测试数据上，保持良好预测性能的能力。

- 算法复杂度（Complexity）：时间复杂度、空间复杂度等

➡ 减少时间复杂度的常用思路

- 简化问题，降低要求
- 用空间换时间
- 用并行化算法，提高并行度

- 模型鲁棒性（Robustness）：系统的健壮性，即系统处理各种非正常数据的能力。包括对数据噪声的处理、对缺失数据及其他不完整数据的处理和对错误数据或含有矛盾数据的处理等。
- 模型适应性：对不同的数据，学习模型本身需要做多少人工调整。一般希望模型本身需要人工指定参数越少越好。自适应模型并不意味着彻底不需要人工指定参数。
- 模型描述的简洁性和可解释性：根据奥坎姆剃刀（Occam's Razor）原则，应该优先选择更简单的假设。模型描述越简洁、越容易理解，就越受欢迎。

机器学习中的数据

假设S是已有数据集，从S中分割出训练数据和测试数据时，训练数据和测试数据要保持同分布。

划分数据的方法有：

保留法（Holdout）

取S的一部分（通常为2/3）作为训练数据，剩余的（通常为1/3）作为测试数据。

深度学习模型通常把S分割为训练集（Train set）、验证集（Validate set）和测试集（Test set）。

训练集和验证集在训练过程中使用，最后在测试集上验证学习成果。

可以将训练集理解为“作业”，验证集理解为“随堂测验”，测试集理解为“期末考试”。

但保留法仅仅使用了部分数据集进行训练，有一部分数据并未利用。因此一般用于数据量非常庞大的情况。

交叉验证法

把S分为k个不相交的子集，取其中一个子集作为测试集，剩余数据作训练集。重复k次，把每一个子集都做一次测试集。得到k个结果，最终的测试结果就是这k个测试结果的平均值。

交叉验证法还可以再重复多次，每次变换不同的k值或者不同的划分。

交叉验证法充分利用了所有已知数据，可以获得较好的学习结果，但是显然需要更长的训练时间。一般用于已知数据量不太大的时候。

随机法

随机抽取S中的一部分数据作为测试数据，把剩下的数据作为训练数据。重复这一过程足够多次，最后的测试结果是所有测试结果的平均值。

随机法可以重复无数次，每个数据都可能被充分地用于训练和测试，可以把测试结果的置信区间减小到指定宽度。



随机法与交叉验证法的区别

随机法中不同的测试集不能看作是对已知数据的独立抽取。而交叉验证法中不同的测试集是独立的，因为一个数据只在测试集中出现一次。

指标

误差 (Error)

误差是指模型预测的结果与真实结果之间的“距离”。

- **理想结果 (E_i)**：数据的真实标签或标准答案 (Ground Truth)。
- **机器学习结果 (L_i)**：模型给出的预测值 (Prediction)。

$$\text{Error}(T) = \sum_{i=1}^T P_i |E_i - L_i|$$

- $|E_i - L_i|$ ：这是单个样本的“差距”。通常用范数（距离）来表示。
- P_i ：样本出现的概率或权重。通常每个样本等权重，即 $P_i = 1/|T|$ 。
- $\sum_{i=1}^{|T|}$ ：把测试集 T 中所有样本的误差累加起来。
- **总结**：误差是所有样本个体误差的**加权总和**。

均方误差 (MSE, Mean Square Error)

$$\text{Error}(T) = \sum_{i=1}^T P_i \sum_{j=1}^d (E_{ij} - L_{ij})^2$$

- **多维处理** ($\sum_{j=1}^d$)：如果预测结果是一个向量（比如坐标 x, y ），则累加每个维度 j 的误差。

MSE是一种L2度量。

当每个样本权重相同且维度为1时：

$$MSE(T) = \frac{1}{|T|} \sum_{i=1}^{|T|} (E_i - L_i)^2$$



例子

假设我们有一个非常简单的模型，用来预测房价（单位：百万元）。我们用 **2 个样本** 来实际计算一下。

- **样本 1**：真实价格 $E_1 = 3$ ，模型预测 $L_1 = 2.5$
- **样本 2**：真实价格 $E_2 = 5$ ，模型预测 $L_2 = 5.5$
- **样本权重**：假设每个样本权重相等，即 $P_i = 1/2 = 0.5$

A. 通用误差 (基于绝对距离)

计算公式： $Error = \sum P_i \cdot |E_i - L_i|$

1. 样本 1 的差距： $|3 - 2.5| = 0.5$

2. 样本 2 的差距： $|5 - 5.5| = 0.5$

3. 加权求和：

$$Error = (0.5 * 0.5) + (0.5 * 0.5) = 0.25 + 0.25 = 0.5$$

B. 均方误差 (MSE)

计算公式： $MSE = \sum P_i * (E_i - L_i)^2$

1. 样本 1 的平方差： $(3 - 2.5)^2 = (0.5)^2 = 0.25$

2. 样本 2 的平方差： $(5 - 5.5)^2 = (-0.5)^2 = 0.25$

3. 加权求和：

$$MSE = (0.5 * 0.25) + (0.5 * 0.25) = 0.125 + 0.125 = 0.25$$

平均绝对误差 (MAE, Mean Absolute Error)

当每个样本权重相同时：

$$MAE(T) = \frac{1}{|T|} \sum_{i=1}^{|T|} |E_i - L_i|$$

MAE是一种L1度量。

正确率（Accuracy）或错误率（Error Rate）

正确率（Accuracy）

被正确处理的数据个数与所有被处理个数的比值。

$$Accuracy(T) = \frac{|T_{error < \epsilon}|}{T}$$


其中， $T_{error < \epsilon}$ 表示被正确处理的数据，也就是误差足够小的数据。

错误率（Error Rate）

没有被正确处理的数据个数与所有被处理的数据个数的比值。

$$ErrorRate(T) = \frac{|T| - |T_{error < \epsilon}|}{|T|} = 1 - Accuracy(T)$$

复合指标



图中的各区域分别代表：

- a：判定属于类且判定正确（True Positive）
- b：判定属于类且判定错误（False Positive）
- c：判定不属于类且判定正确（True Negative）
- d：判定不属于类且判定错误（False Negative）



正确率（Accuracy）的另一种表示方法

正确率是被处理正确的数据个数占有所有被处理数据的比值，因此有：

$$Accuracy(T) = \frac{TP + TN}{TP + FP + TN + FN}$$

精度（Precision）

也称命中率、准确率。

$$precision(T) = \frac{TP}{TP + FP}$$

召回率（Recall, True Positive Rate）

也称覆盖率、灵敏度（Sensitivity）。度量漏判率，也就是所有的真实正样本中，有多少正样本被准确判定。

$$recall(T) = \frac{TP}{TP + FN}$$



精度和召回率的物理意义

指标	物理意义	核心目标	业务极端案例
Precision (精度)	查准率：预测为正类的样本中，“真货”有多少？	减少误报 (FP)	垃圾邮件过滤：不能把老板的邮件当成垃圾邮件。
Recall (召回率)	查全率：所有的“真货”里，你抓到了多少？	减少漏报 (FN)	医疗筛查：不能漏掉任何一个潜在的患者。

特异度（Specificity, True Negative Rate）

对阴性的召回率，度量误判率，也就是所有的真实负样本中，有多少负样本被准确判定。

$$Specificity(T) = TNR(T) = \frac{TN}{TN + FP}$$

假阳性率（False Positive Rate, 1-Specificity）

度量误判率。

$$FPR = 1 - Specificity = \frac{FP}{TN + FP}$$

假阴性率 (False Negative Rate, 1-Sensitivity)

度量漏判率。


$$FNR = 1 - Sensitivity = \frac{FN}{TP + FN}$$

ROC (Receiver Operation Characteristic) 曲线

受试者工作特征曲线，是评估二分类模型性能的图形化工具。它直观展示了模型在不同**决策阈值** (Threshold) 下，对正负样本的区分能力。

ROC 曲线建立在二维坐标系中，通过两个关键指标绘制：

- **纵坐标 (TPR)**：真正例率 (True Positive Rate)，即**灵敏度**或**召回率**。表示实际为正的样本中，被模型正确预测为正的比率。
- **横坐标 (FPR)**：假正例率 (False Positive Rate)。表示实际为负的样本中，被模型错误预测为正的比率。



ROC曲线是如何绘制的？

分类模型通常会输出一个 0 到 1 之间的概率值。

- 我们需要设定一个**阈值 (Threshold)**。
- 如果阈值是 0.8，超过 0.8 才算“阳性”。
- **滑动阈值**：从 1 变动到 0，每动一下，就会产生一对新的 (FPR, TPR)。
- 把这些点连起来，就是 ROC 曲线。

曲线越靠近左上角，模型越完美。

从左上角 $(0, 1)$ 到右下角 $(1, 0)$ 的对角线代表了 $FPR + FNR = 1$ 的轨迹。因此其与ROC曲线的交点意味着模型在此决策阈值时， $FPR + FNR = 1$ 。

即有：

$$FPR + TPR = \frac{FP}{FP + TN} + \frac{TP}{TP + FN} = 1$$

而又有：

$$FNR + TPR = \frac{FN}{FN + TP} + \frac{TP}{TP + FN} = 1$$

因此有：

$$FPR = FNR$$

因此此点被称为等错误率点，在这个决策阈值下，假阳性率和假阴性率相同，也就是错误地判断为阳性和错误地判断为阴性的概率相同。

AUC或AUROC (Area Under ROC Curve)

ROC曲线下方的总面积。可以理解为对一个模型的综合评分。

- **AUC = 1.0**：完美模型。此时ROC曲线完全覆盖坐标轴。
- **AUC = 0.5**：毫无用处的模型。此时ROC曲线为随机概率线下方的三角形，模型没有任何判断作用，仅进行随机判断。
- **AUC > 0.8**：通常被认为是性能很优秀的模型。

F_β 度量 (F_β - Measure)

对模型的评分。

数学定义为在召回率 ($recall(T) = \frac{TP}{TP+FN}$) 的重要性 (权重) 是精度 ($precision(T) = \frac{TP}{TP+FP}$) 的 β^2 倍时，召回率和精度的调和平均值。

$$F_\beta = \frac{(1 + \beta^2)}{\left(\frac{1}{precision(T)} + \frac{\beta^2}{recall(T)}\right)}$$

化简后有：

$$F_\beta = \frac{(1 + \beta^2) \cdot precision(T) \cdot recall(T)}{\beta^2 \cdot precision(T) + recall(T)}$$



为什么用 β^2 而不是 β ？

这主要是一种数学惯例。它确保了当 $\beta = 1$ 时，两个指标权重绝对相等。且在求导计算最优化问题时，平方项能抵消根号或简化系数。



举例： β 变化对评价结果的影响

假设我们有一个地震预测模型：

场景 A：宁可错报，不可漏掉 $\beta = 2$

- **物理意义**：漏掉地震（Recall 低）会导致生命损失，而误报（Precision 低）只是虚惊一场。
- **影响**：当 $\beta = 2$ 时，公式会给 Recall 权重更大。如果模型为了多抓出几个地震而导致精度下降，只要 Recall 提升明显， F_2 依然会升高。
- **结论**： $\beta > 1$ 时，模型表现受 **Recall** 支配。

场景 B：宁可漏掉，不可错报 $\beta = 0.5$

- **物理意义**：如果地震预警会导致全市紧急停工、损失百亿，我们要求预测必须极其准确。
- **影响**：当 $\beta = 0.5$ 时，公式更看重 Precision。如果模型虽然抓住了所有地震（Recall=1），但误报率很高，其 $F_{0.5}$ 分数会非常低。
- **结论**： $\beta < 1$ 时，模型表现受 **Precision** 支配。

一个识别肿瘤模型，针对同一种表现，计算不同 β 下的得分

假设：

Precision = 0.6 (判定的肿块中，只有60%是真的)

Recall = 0.9 (抓住了90%的真实肿块)

1. $\beta = 1$ (平衡视角 - F1 Score)

$$F_1 = \frac{2 \times 0.6 \times 0.9}{0.6 + 0.9} \approx 0.72$$

- 评价：中规中矩，综合反映模型性能。

2. $\beta = 2$ (侧重查全 - F2 Score)

$$F_2 = \frac{(1 + 2^2) \times 0.6 \times 0.9}{2^2 \times 0.6 + 0.9} = \frac{5 \times 0.6 \times 0.9}{4 \times 0.6 + 0.9} \approx 0.81$$

- 评价：分数上升。因为该模型 Recall 高，当 $\beta=2$ 时，高 Recall 极大地拉高了总分。

3. $\beta = 0.5$ (侧重查准 - F0.5 Score)

$$F_{0.5} = \frac{(1 + 0.5^2) \times 0.6 \times 0.9}{0.5^2 \times 0.6 + 0.9} = \frac{1.25 \times 0.6 \times 0.9}{0.25 \times 0.6 + 0.9} \approx 0.64$$


- 评价：分数下降。因为该模型 Precision 较低，当 $\beta=0.5$ 时，系统对“不准”的容忍度极低，从而严厉惩罚了总分。

多分类问题学习结果的评判

对于测试集T，目标类别共有k个。

混淆矩阵（Confusion Matrix）

是衡量分类模型性能的核心工具。它通过矩阵的形式，展示了模型预测结果与真实标签之间的对比情况。



图中的混淆矩阵，行表示预测结果，列表示真实结果。

对角线上的数值为 True Positive，第一行除对角线外的数字代表 False Positive，第一列除对角线外的数字代表 False Negative.

通过混淆矩阵可以计算各种指标。

宏平均法（Macro Average）

宏平均（Macro Average）是处理多分类问题时最常用的评估方法之一。它的核心思想是**平等地对待每一个类别**，而不考虑类别中样本的数量。

假设目标类别共有 k 个，对于每一个类别 i ，我们先计算其独立的精确率 ($Precision_i$) 和召回率 ($Recall_i$)。

宏平均精确率 (Macro-Precision):

$$Precision_{macro} = \frac{1}{k} \sum_{i=1}^k Precision_i$$

宏平均召回率 (Macro-Recall):

$$Recall_{macro} = \frac{1}{k} \sum_{i=1}^k Recall_i$$

宏平均 F1 值 (Macro-F1)

通常有两种计算方式，业界最常用的是对各类的 $F1$ 值求算术平均：

$$F1_{macro} = \frac{1}{k} \sum_{i=1}^k F1_i$$

其中，每一类的 $F1$ 计算如下：

$$F1_i = \frac{2 \times Precision_i \times Recall_i}{Precision_i + Recall_i}$$

微平均法 (Micro Average)

微平均 (Micro Average) 与宏平均不同，它不按类别求均值，而是**站在全体样本的角度**。它把所有类别的预测情况合并在一起计算，视为一个单分类问题，并给每一个样本平等的权重。

假设共有 k 个类别，对于每一个类别 i ，其对应的混淆矩阵分量为 $|a_i|$ (TP)、 $|b_i|$ (FP) 和 $|d_i|$ (FN)。

微平均精确率 (Micro-Precision):

$$Precision_{micro} = \frac{\sum_{i=1}^k |a_i|}{\sum_{i=1}^k |a_i| + \sum_{i=1}^k |b_i|}$$

微平均召回率 (Micro-Recall):

$$Recall_{micro} = \frac{\sum_{i=1}^k |a_i|}{\sum_{i=1}^k |a_i| + \sum_{i=1}^k |d_i|}$$

微平均 F1 值 (Micro-F1):

$$F1_{micro} = \frac{2 \times Precision_{micro} \times Recall_{micro}}{Precision_{micro} + Recall_{micro}}$$